MACHINE LEARNING

Master 2 ISF – Université Paris-Dauphine

Année Scolaire 2026-2027

Support #1

Exploration et visualisation de la donnée

Jorge OCHOA

© Tous droits réservés.

Présentation

Ingénieur en Génie Mathématique - INSA de Rouen

Master 2 en Actuariat – Université Paris-Dauphine

Actuaire certifié de l'Institut des Actuaires

Consultant Senior – Optimind/Accenture (*2019-2026*)

- Actuaire au sein du service *Actuarial and Financial Services* (IARD et Santé/Prév)
- Expertise Leader de l'Expertise Center Data Valuation

Actuaire Pricing Auto – Axa France (*2026-*)

Actuaire au sein de l'équipe de tarification Auto particuliers

Contact : jorge.ochoa.pro19@gmail.com

Sommaire

01
Organisation du cours

02
Rappels Python et bonnes pratiques

03
La démarche d’un Data Scientist

01

Organisation du cours

Organisation du cours

Objectifs :

- Connaître la démarche à suivre pour un projet de Data Science
- Analyser et visualiser la donnée
- Comprendre et appliquer des algorithmes simples de Machine Learning

Prérequis :

- Langage Python

Séance # 1 (3 h) : Rappels Python + Exploration et visualisation de la donnée (cours + TP)
Séance # 2 (3 h) : Les algorithmes non supervisés (cours + TP)
Séance # 3 (3 h) : Les algorithmes supervisés (cours)
Séance # 4 (3 h) : Les algorithmes supervisés (TP - Régression)
Séance # 5 (3 h) : Les algorithmes supervisés (TP - Classification)
Séance # 6 (3 h) : Les algorithmes supervisés + Consignes du projet

Le contrôle de connaissances se fera sous forme d'épreuve écrite (40%) et un projet en binômes/trinômes (60%)

Ce cours est inspiré des notes de cours de M. Patrice BERTRAND et M. André GRONDIN (Université Paris-Dauphine)

Accès aux supports de cours

- Les supports de cours ainsi que les TP seront disponibles via le lien :

Partage_étudiants

- Vous devez vous connecter à votre compte Dauphine pour y accéder

02

Bonnes pratiques Python

Le langage Python

- Le langage **Python** est un langage de programmation créé en **1981 par Guido van Rossum** aux Pays-Bas

- Plusieurs versions ont existé depuis la première version gratuite de 1991. La dernière version de Python est la version 3

- Ce langage est très répandu notamment en raison de ses caractéristiques :
  - Langage multiplateforme
  - Gratuit
  - Langage de haut niveau
  - Langage interprété
  - Langage multiparadigme
  - Relativement facile à prendre en main



Bonnes pratiques

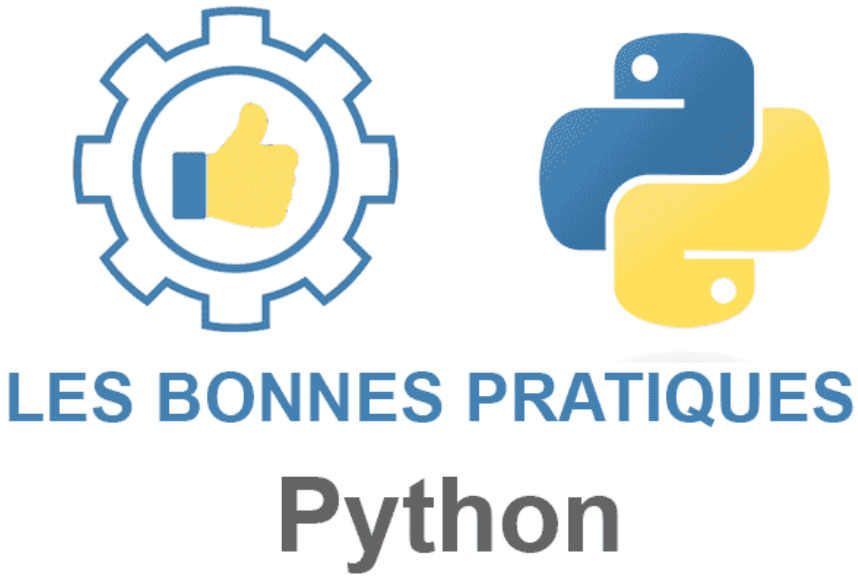
- Commentez le code

- **Evitez les boucles** (for, while, etc.) pour faire des opérations ligne à ligne ou sur tous les éléments

- **Attention aux boucles infinies!** Mettre toujours une condition d'arrêt

- Utilisez des noms explicites :
  - Des **noms explicites pour les variables (à écrire en minuscule)**
  - Des **verbes pour les fonctions**
  - En **majuscules pour les constantes**

- **Lisibilité du code :**
  - Indentation
  - Espaces entre les opérateurs
  - Retours à la ligne



03

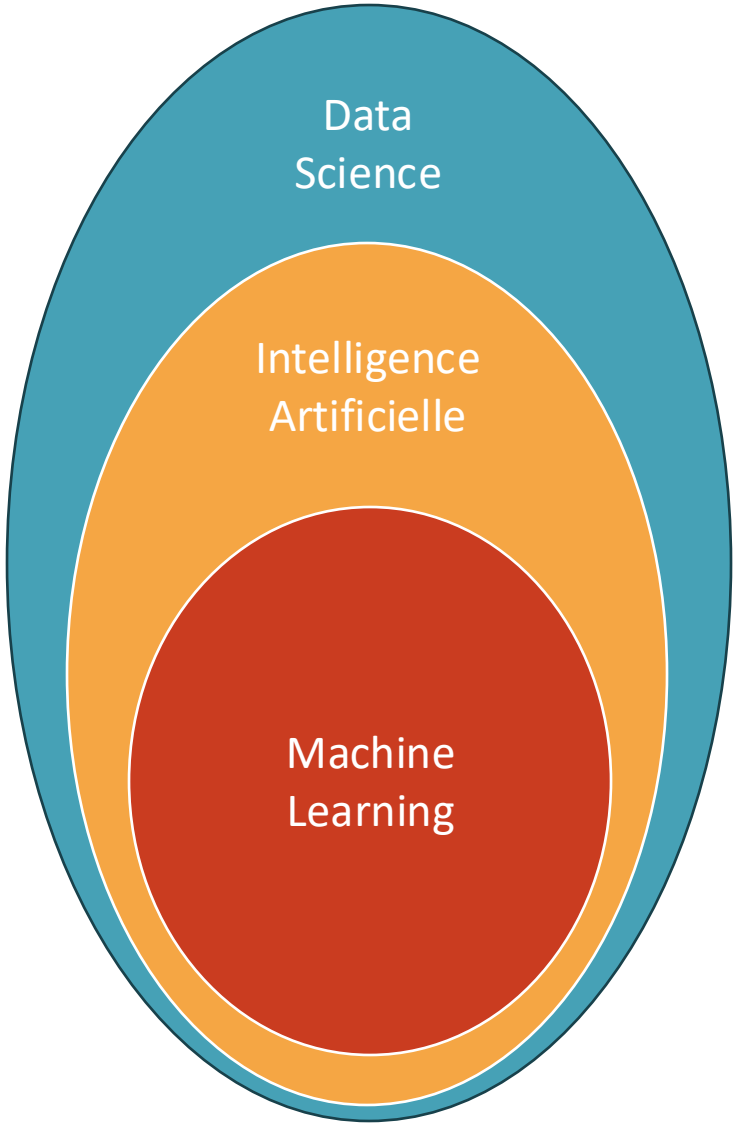
La démarche d’un Data Scientist

Data Science

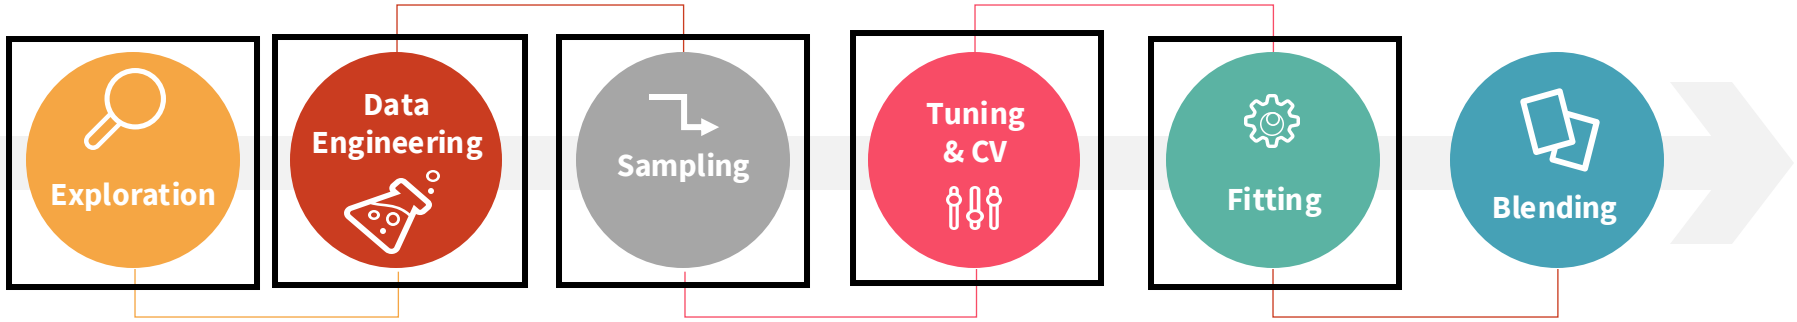
- La ***Data Science*** **ou Science des Données** désigne un mélange **multidisciplinaire** d'inférence de données, de développement d'algorithmes et de technologie

- En termes pratiques, la *Data Science* consiste à utiliser les données de manière créative et innovante pour **générer de la valeur**

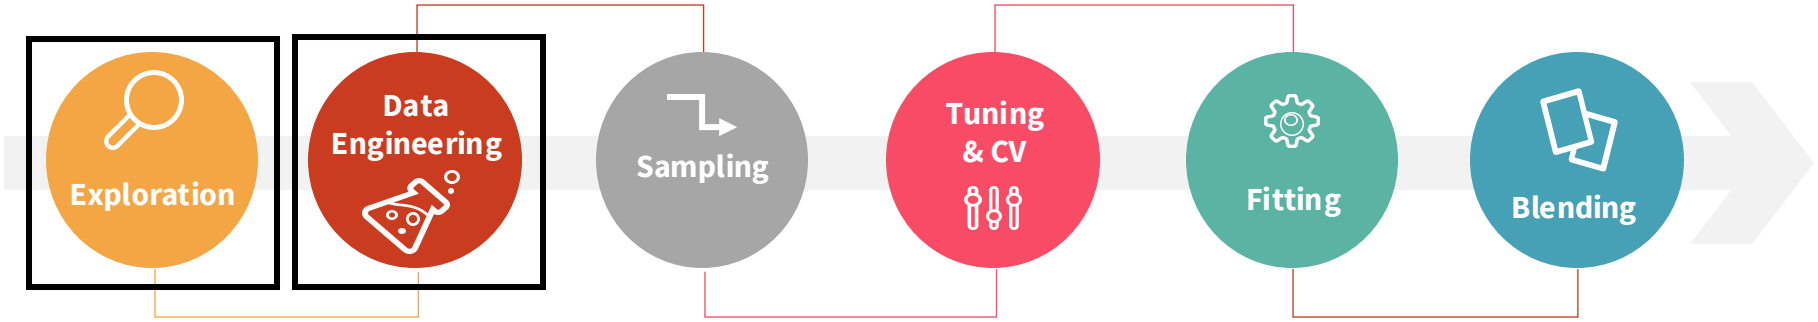
- Parmi ses disciplines les plus populaires, se trouvent :
  - La *Data Visualization*
  - Le *Machine Learning*
  - L'Intelligence Artificielle



Démarche classique d'un projet de Data Science



Démarche classique d'un projet de *Data Science*



Dimensions de la base
- Nombre de lignes
- Nombre de colonnes
- Poids

Type de données
- Integer
- Float
- String
- Date

Description des données
- Modalités caractéristiques
- Visualisation de la donnée

Données manquantes
- suppression
- correction
- imputation

Valeurs extrêmes
- correction
- suppression
- étude d'impact

Transformation des données
- discrétisation
- mise à l'échelle
- découpage
- one-hot encoding