Année Scolaire 2026/2027

Master 2 - ISF
Machine Learning en Python
Consignes du projet

1. Consignes générales

Afin de valider l'UC « Machine Learning en Python », vous devez réaliser un projet (60% de la note finale) **par trinômes**.

L'objectif de ce projet est de mettre en application la démarche à suivre dans le cadre d'un projet de *Data Science* ainsi que les différents éléments vus en cours (algorithmes, techniques de sampling, cross-validation, one hot encoding, etc.) pour traiter un problème concret (décrit dans §2).

Les livrables attendus de votre part sont :

- **Le code**, dûment commenté, qui vous a permis d'obtenir vos résultats. Ce dernier peut être un Jupyter Notebook ou un script Python réalisé sous un autre logiciel (Spyder, Google Colab, etc.).
- Un **fichier** Jupyter Notebook, HTML, Rmarkdown ou autre **contenant l'exécution de votre code** et affichant vos résultats.
- **Un rapport de maximum 30 pages (au format PDF)** présentant votre démarche, résultats, raisonnement, conclusions et les limites de votre projet. A titre d'exemple, vous pourrez suivre le plan suivant :
    - Présentation/Description des données
    - Retraitements appliqués
    - Modélisation 1
        - Démarche suivie
        - Sampling et hyperparamétrage
        - Cross-Validation
        - Résultats
        - Analyse des résultats
    - Modélisation 2
    - …
    - Conclusion, limites et axes d'améliorations
    - Annexes (non comptabilisés dans les 25 pages).

Il est impératif d'utiliser au moins un des algorithmes vus en cours.
N'hésitez pas à illustrer vos explications via des captures d'écran et graphiques issus de votre code.

L'envoi du projet doit être fait par un seul membre du groupe (avec les autres membres en CC) et les livrables contenus dans un fichier .zip nommé avec les noms de famille des membres.
Exemple : le groupe 1 composé de M.X, Mme.Y et M.Z enverra un fichier nommé Projet_X_Y_Z.zip

Les projets doivent être envoyés à l'adresse jorge.ochoa.pro19@gmail.com au plus tard le 20/12/2026 à 23h59.

2. Cas d'usage

Vous êtes consultant au sein de l'équipe Data Science & Customer Analytics de Disney+.

Dans un marché très concurrentiel des plateformes de streaming, la fidélisation des abonnés constitue un enjeu majeur. Le départ d'un abonné représente non seulement une perte de revenus, mais également la perte des opportunités futures de développer sa relation avec la plateforme.

La direction de Disney+ souhaite donc mettre en place une démarche fondée sur les données afin de **mieux comprendre les comportements associés à la résiliation des abonnements et d'anticiper les départs des abonnés**.

Vous disposez d'un jeu de données contenant différentes informations relatives aux abonnés de la plateforme : caractéristiques des clients, informations relatives à leur abonnement ainsi que plusieurs indicateurs décrivant leur utilisation et leur engagement vis-à-vis du service.

Votre mission consiste à exploiter ces données afin de développer des modèles de **Machine Learning permettant d'améliorer la compréhension et l'anticipation de la résiliation des abonnements**. Les modèles développés doivent finalement permettre à Disney+ de passer de la prédiction à l'action.

L'objectif est de pouvoir répondre à une question opérationnelle : q**uels abonnés présentent un risque de résiliation, pourquoi sont-ils considérés comme à risque et à quel moment une action de fidélisation devrait-elle être envisagée ?**

Votre travail devra donc mettre en évidence non seulement les performances des modèles développés, mais également leur **interprétabilité, leurs limites et leur intérêt pour une utilisation opérationnelle**.
Le projet est organisé en **deux volets complémentaires :**

a. Comprendre et expliquer la résiliation

Dans un premier temps, la direction souhaite répondre à une question essentielle : **quels sont les facteurs associés à la résiliation d'un abonnement Disney+ ?**

Vous devrez construire un ou plusieurs **modèles de classification** permettant d'identifier les abonnés susceptibles de résilier leur abonnement.

Cependant, la performance prédictive du modèle ne constituera pas le seul objectif. La direction souhaite également comprendre **pour quelles raisons un abonné est identifié comme présentant un risque de résiliation**.
Vous devrez donc analyser et interpréter les résultats obtenus afin notamment de déterminer :

- Quelles caractéristiques sont associées à la résiliation ?
- Quels profils d'abonnés présentent un risque plus important ?
- Quelles variables contribuent le plus aux prédictions ?
- Dans quelle mesure les résultats obtenus sont cohérents avec les observations réalisées lors de l'analyse exploratoire ?
- Comment expliquer la prédiction obtenue pour un abonné particulier ?

b. Anticiper le moment de la résiliation

Identifier les abonnés susceptibles de partir constitue une première étape. Pour pouvoir mettre en place des actions de fidélisation efficaces, Disney+ souhaite aller plus loin et identifier à quel moment un abonné est susceptible de résilier.

Dans un second temps, vous devrez donc développer une méthode permettant **d'estimer le délai avant la résiliation**.

Cette nouvelle problématique introduit une dimension temporelle. Il ne s'agit plus uniquement de déterminer **si** un abonné va résilier, mais également **quand** cette résiliation est susceptible d'intervenir.

Vous devrez notamment vous interroger sur :

- La définition de la variable à prédire.
- Les informations disponibles avant la résiliation et celles qui ne peuvent pas être utilisées.
- Le risque de fuite d'information (*data leakage*).
- Les limites et hypothèses associées à votre approche.

Vous êtes libres de proposer et de comparer différentes approches, à condition de **justifier vos choix méthodologiques**.